


Projekt 6

NCG jako solver regresji logistycznej

Wykonały

Alicja Pakulska, Krystyna Trzusto



Cel projektu

Cel główny: Zastosowanie metod optymalizacji ciągłej do problemu regresji logistycznej.

Eksperyment przeprowadzono na zbiorze danych `breast_cancer` z biblioteki `sklearn.datasets`.

Porównywane metody

- **Gradient Descent**

ze stałym krokiem

- **NCG-PRP+**

z backtrackingiem Armijo

- **Newton-Raphson**

z backtracking line search

Badane metryki

Dla każdej z metod szczegółowo przeanalizowano i porównano następujące wskaźniki:

- Liczba iteracji
- Czas działania (szybkość)
- Końcowa wartość funkcji straty
- Dokładność (accuracy) na zbiorze testowym

Dane i przygotowanie danych

Dane wejściowe

Wykorzystano zbiór `breast_cancer` z biblioteki `sklearn.datasets`.

Charakterystyka zbioru:

569 obserwacji (próbek)

30 cech numerycznych

2 klasy decyzyjne (diagnozy)

Przygotowanie danych

Przed trenowaniem modelu wykonano kluczowe kroki przetwarzania wstępnego:

- Podział danych na zbiór treningowy oraz testowy
- Standaryzacja cech (skalowanie zmiennych)
- Zamiana etykiet klas z $\{0, 1\}$ na $\{-1, 1\}$
- Dodanie kolumny jedynek (bias) dla wyrazu wolnego

Funkcja straty logistycznej

Regresja logistyczna jako problem optymalizacji

Minimalizowana funkcja straty logistycznej:

$$\ell(w) = - \sum_{i=1}^m [y_i \log \sigma(w^T x_i) + (1 - y_i) \log(1 - \sigma(w^T x_i))] , \quad \sigma(t) = \frac{1}{1 + e^{-t}}.$$

Objaśnienie symboli

w — wektor parametrów modelu

x_i — wektor cech pojedynczej obserwacji

y_i — etykieta klasy

m — liczba obserwacji treningowych

Własna implementacja

Projekt obejmował samodzielne przygotowanie kluczowych komponentów matematycznych:

- ✓ funkcja straty
- ✓ gradient
- ✓ hesjan

Część podstawowa projektu

Pipeline regresji logistycznej

Kolejne etapy realizacji części podstawowej:

1. Wczytanie zbioru `breast_cancer`
2. Przygotowanie i podział danych do treningu
3. Implementacja funkcji straty, gradientu i hesjanu
4. Optymalizacja trzema metodami:
 - Gradient Descent (stały krok)
 - NCG-PRP+ (z backtrackingiem)
 - Newton-Raphson (line search)

Porównanie i ocena

Każdą z zastosowanych metod optymalizacji porównujemy pod kątem kluczowych metryk:

- Liczba iteracji do zbieżności
- Czas obliczeniowy procesora (CPU)
- Końcowa wartość funkcji straty logistycznej
- Dokładność (accuracy) na zbiorze testowym

Porównywane metody

Metoda	Charakterystyka
Gradient Descent	metoda pierwszego rzędu, stały krok
NCG-PRP+	metoda gradientów sprzężonych, Armijo
Newton-Raphson	metoda drugiego rzędu, używa hesjanu

Gradient Descent

Najprostszy algorytm, ale może wymagać wielu iteracji do osiągnięcia zbieżności.

NCG-PRP+

Nie wymaga obliczania hesjanu, efektywnie wykorzystuje informacje z poprzednich gradientów.

Newton-Raphson

Wykorzystuje hesjan, potrzebuje mniej iteracji, ale pojedynczy krok jest kosztowny obliczeniowo.

Wyniki części podstawowej

Wyniki metod

Metoda	Iteracje	Warunek stopu	Loss	Accuracy test
Gradient Descent	5000	NIE	0.0446	0.9825
NCG-PRP+	1000	NIE	0.0411	0.9825
Newton-Raphson	88	TAK	0.0000737	0.9474

Interpretacja

- **GD i NCG-PRP+** uzyskały najwyższe accuracy testowe.
- **Newton-Raphson** osiągnął najniższą wartość funkcji straty.
- **Newton** spełnił warunek stopu przy znacznie mniejszej liczbie iteracji.

Wykresy zbieżności



Zbieżność metod

Na wykresach przedstawiono:

- wartość funkcji straty w kolejnych iteracjach,
- normę gradientu w kolejnych iteracjach.

Wnioski z wykresów

- **Wszystkie metody** zmniejszały wartość funkcji celu.
- **Gradient Descent** zmniejszał stratę stopniowo.
- **NCG-PRP+** osiągnął nieco niższą stratę niż GD.
- **Newton-Raphson** najszybciej zmniejszał wartość funkcji straty.



Wnioski z części podstawowej

Ogólne obserwacje

- **Efektywność:** Wszystkie trzy metody skutecznie minimalizowały funkcję straty logistycznej.
- **Trening vs Test:** Niższa strata na zbiorze treningowym nie zawsze oznaczała lepsze accuracy na zbiorze testowym.

Specyfika algorytmów

- **Gradient Descent:** Najprostszy w działaniu, ale potrzebował zdecydowanie największej liczby iteracji do zbieżności.
- **Newton-Raphson:** Najszybciej zmniejszył stratę i jako jedyny w pełni spełnił zdefiniowany warunek stopu.

Potencjał metody NCG

- **NCG-PRP+:** Uzyskał bardzo dobre accuracy testowe całkowicie bez liczenia macierzy hesjanu.
- **Alternatywa:** NCG stanowi praktyczną, wydajną alternatywę dla Newtona, gdy chcemy uniknąć kosztu pamięciowego hesjanu.

Część rozszerzona projektu

W części rozszerzonej sprawdzamy dodatkowe aspekty działania metod:

Koszt pamięciowy

- Bezpośrednie porównanie zużycia pamięci **NCG** oraz **Newtona**.
- Wykazanie, że **NCG nie wymaga** przechowywania hesjanu.
- Analiza kwadratowego kosztu macierzy hesjanu dla metody Newtona.

Zbieżność i warianty

- Szczegółowa analiza **wykresów zbieżności** obu metod.

Porównanie i testy trzech wariantów NCG:

- **FR** (Fletcher-Reeves)
- **PRP+** (Polak-Ribière+)
- **HS** (Hestenes-Stiefel)

Walidacja i L2

- Badanie wpływu **regularyzacji L2** na stabilność i wyniki.
- Porównanie własnej implementacji z referencyjnym kodem z biblioteki:

```
sklearn.linear_model.LogisticRegression
```

Cel analizy: Ta część pokazuje, w jakich warunkach i kiedy optymalizacja metodą NCG stanowi praktyczną, wydajniejszą alternatywę dla metody Newtona.

Memory footprint NCG i Newtona

Metoda NCG

Złożoność: $O(n)$ — liniowa

Metoda pierwszego rzędu. W praktyce przechowuje głównie kilka wektorów: wektor wag, gradient oraz kierunek poszukiwań.

Z tego powodu pamięć potrzebna na część optymalizacyjną rośnie liniowo.

Metoda Newtona-Raphsona

Złożoność: $O(n^2)$ — kwadratowa

Metoda drugiego rzędu. Korzysta z hesjanu, czyli macierzy drugich pochodnych o rozmiarze $n \times n$.

Jej koszt pamięciowy rośnie kwadratowo wraz ze wzrostem liczby parametrów.

Wpływ rozmiaru modelu

Dla zbioru **breast_cancer** liczba parametrów jest mała, ale przy dużych modelach ta różnica staje się **bardzo istotna**.

Tabela 1. Porównanie przybliżonego zużycia pamięci.

Liczba parametrów	NCG $O(n)$ [MB]	Newton [MB]	$O(n^2)$	Newton / NCG
31	0.000710	0.007805		11
1000	0.022888	7.6447		334
10000	0.228882	763.09		3334

Warianty NCG: FR, PRP+ i HS

Warianty metody

W rozszerzeniu porównano trzy warianty nieliniowej metody gradientów sprzężonych:


- Fletcher-Reeves
- Polak-Ribiere+
- Hestenes Stiefel

Wszystkie warianty korzystają z tego samego backtrackingu Armijo, aby porównanie dotyczyło głównie sposobu wyznaczania współczynnika beta i kierunku poszukiwań.


Tabela 2. Porównanie wariantów NCG.

Wariant	Iteracje	Stop	Czas CPU [s]	Strata końcowa	Accuracy test	Liczba restartów
FR	1000	Nie	0.139530	0.014906	0.956140	0
PRP+	1000	Nie	0.140797	0.041097	0.982456	1000
HS	1000	Nie	0.144751	0.041097	0.982456	1000

Warianty NCG - norma gradientu





Warianty NCG - funkcja straty



Regularyzacja L2

Tabela 3. Wpływ regularyzacji L2 na wynik NCG-PRP+.

Lambda	Iteracje	Stop	Strata bez kary	Strata z karą	Accuracy test	Norma wag bez biasu
0	1000	Nie	0.041097	0.041097	0.982456	5.9761
0.000100	1000	Nie	0.041592	0.043242	0.982456	5.7449
0.001000	1000	Nie	0.046139	0.055888	0.982456	4.4156
0.010000	745	Tak	0.069100	0.096556	0.964912	2.3434
0.100000	164	Tak	0.134006	0.194993	0.964912	1.1044
1	49	Tak	0.284727	0.382504	0.912281	0.442215



Porównanie z LogisticRegression ze sklearn

Tabela 4. Porównanie własnych metod z LogisticRegression.

Metoda	Accuracy test	Strata treningowa
wlasne GD	0.982456	0.044568
wlasne NCG-PRP+	0.982456	0.041097
wlasny Newton-Raphson	0.947368	0.000074
sklearn LogisticRegression	0.982456	-

Wnioski z części rozszerzonej



NCG jako kompromis

Metoda NCG stanowi optymalny kompromis pomiędzy prostym GD a zaawansowaną metodą Newtona-Raphsona.

- **Wobec GD:** korzysta z informacji z poprzednich iteracji, tworząc lepsze kierunki poszukiwań.
- **Wobec Newtona:** nie wymaga hesjanu, przez co jest znacznie tańsza pamięciowo.



NCG vs Metoda Newtona

Newton szybko minimalizuje funkcję celu, ale wymaga kosztownego liczenia i przechowywania hesjanu.

- **Funkcja straty:** NCG nie osiąga tak niskiej straty jak Newton w tym badaniu.
- **Wydajność:** NCG zapewnia bardzo dobrą dokładność testową przy ułamku kosztu pamięci.



Regularyzacja L2

Zastosowanie dodatkowej regularyzacji L2 wnosi istotną kontrolę nad procesem uczenia.

- **Kontrola wag:** pozwala bezpośrednio wpływać na wielkość parametrów modelu.
- **Generalizacja:** skutecznie ogranicza ryzyko zbyt mocnego dopasowania (overfittingu).